

STATYSTYCZNA ANALIZA DANYCH

SPRAWOZDANIE - PROJEKT

Małgorzata Pawlisiak 163776
Bioinformatyka semestr IV

1. Instrukcja obsługi i opis skryptu:

Skrypt został zaprojektowany w celu przeprowadzania kompleksowej **statystycznej analizy danych medycznych**. Głównym zadaniem skryptu jest przekształcenie wyników badań pacjentów w kompleksowy raport i utworzenie wizualizacji danych, aby w łatwy sposób przedstawić zależności pomiędzy konkretnymi wartościami.

Skrypt jest w pełni zautomatyzowany (uzupełnia braki danych, wyłapuje błędne wartości i przeprowadza dopasowane testy statystyczne), a także przystosowany do pracy z różnymi typami danych (dowolne parametry i grupy badawcze).

Skrypt można uruchomić w 2 trybach:

-> Tryb wsadowy:

Skrypt można uruchomić w trybie wsadowym za pomocą następującego polecenia:

"C:\Program Files\R\R-4.5.2\bin\Rscript.exe" Projekt-Małgorzata-Pawlisiak.R NazwaPliku.csv

NazwaPliku.csv -> Nazwa pliku, który chcemy poddać analizie w formacie .CSV

W przypadku nie podania argumentu (nazwy pliku .csv) skrypt przyjmuje plik **przykladoweDane-Projekt.csv** jako argument domyślny.

-> Tryb interaktywny:

Skrypt można uruchomić w trybie interaktywnym w środowisku takim jak **RStudio**.

Należy załadować plik .R i kliknąć **Source** lub wykonywać kod linijka po linijce.

Jest to wygodna opcja, jeśli chcemy prześledzić poszczególne etapy analizy lub zmodyfikować parametry (np. zmienić kolory wykresów).

Opis skryptu:

-> Przygotowanie danych i obsługa braku danych:

Skrypt identyfikuje braki danych i zastępuje je wartością średnią wyliczoną dla danej kolumny. Jest to metoda pozwalająca na zachowanie liczności grup bez konieczności usuwania całych rekordów.

Skrypt identyfikuje wartości odstające (outliers) za pomocą metody rozstępu międzykwartylowego (boxplot stats - wyznaczania zakresu w okolicy 50% najbardziej typowych wyników), a następnie przedstawia je w raporcie.

-> Charakterystyka grup:

Skrypt oblicza statystyki - średnią arytmetyczną, medianę, odchylenie standardowe oraz liczebność grupy i prezentuje je w formie tabeli.

-> Analiza porównawcza:

Skrypt przeprowadza test normalności rozkładu Shapiro-Wilka i test jednorodności wariancji Levene'a. Jeśli dane spełnią warunki obu testów, skrypt wybiera podstawowy test ANOVA. Gdy ANOVA wykryje różnice między grupami pacjentów, uruchamiany jest test post-hoc Tukeya, aby precyzyjnie wskazać, które konkretnie grupy się różnią. Jeśli dane nie spełnią warunków przynajmniej jednego z testów sprawdzających, skrypt automatycznie wykorzystuje alternatywny test Kruskala-Wallisa. Gdy wykryje on różnice, przeprowadzany jest test post-hoc Dunna, aby wskazać różniące się pary.

-> Analiza korelacji:

Skrypt bada zależności między parametrami wewnątrz każdej z grup przy użyciu współczynnika korelacji rangowej Spearmana. Skrypt raportuje tylko te pary, dla których korelacja jest istotna statystycznie ($p < 0.05$).

Charakterystyka testów:

-> Test Shapiro-Wilka - sprawdza zgodność rozkładu danych z rozkładem normalnym (weryfikuje, czy większość wyników skupia się wokół średniej, a wartości skrajne występują stosunkowo rzadko).

-> Test Levene'a - sprawdza jednorodność wariancji, czyli czy wyniki wewnątrz badanych grup charakteryzują się podobnym rozrzutem (zmiennością) i nie dochodzi do sytuacji, w której dane w jednej grupie są bardzo skupione, a w innej mocno rozproszone.

-> Test ANOVA - porównuje wartości średnie między grupami, aby sprawdzić, czy ogólny poziom badanego parametru różni się między nimi w sposób istotny statystycznie (dane spełniające założenia o normalności i jednorodności wariancji).

-> Test post-hoc Tukeya - jest przeprowadzany po teście ANOVA (gdy ten wykaże ogólne różnice), aby precyzyjnie wskazać, między którymi konkretnie parami grup występuje statystycznie istotna różnica (np. CHOR1 vs KONTROLA).

-> Test Kruskala-Wallisa - stanowi nieparametryczną alternatywę dla testu ANOVA, stosowaną w przypadku niespełnienia założeń o normalności lub jednorodności wariancji.

Opiera się na porównywaniu rang (pozycji) danych, dzięki czemu pojedyncze wartości odstające nie zniekształcają ostatecznego wyniku.

-> **Test post-hoc Dunna** - stanowi odpowiednik testu Tukeya stosowany po teście Kruskala-Wallisa, pozwala na szczegółowe porównanie par grup w celu wskazania, między którymi z nich zachodzą statystycznie istotne różnice w rozkładzie wyników.

-> **Współczynnik korelacji rangowej Spearmana** - bada siłę i kierunek zależności między dwoma parametrami (zamiast dokładnych surowych wartości porównuje ich pozycje w rankingu, weryfikując, czy wzrostowi jednego parametru towarzyszy wzrost lub spadek drugiego, dzięki czemu pojedyncze wartości skrajne nie zaburzają ostatecznego wyniku).

2. Szczegółowy opis skryptu:

Poniższa sekcja stanowi techniczną dokumentację kodu, wyjaśniającą działanie poszczególnych mechanizmów skryptu. W celu optymalizacji pracy, skrypt wykorzystuje specjalną listę o nazwie raport, do której na bieżąco na każdym etapie analizy, zapisuje uzyskane wyniki (np. uzupełnione braki, wyliczone statystyki, wyniki testów).

```
suppressPackageStartupMessages({
  library(Hmisc)
  library(dplyr)
  library(ggpubr)
  library(car)
  library(FSA)
  library(dunn.test)
  library(corrplot)
})
options(width = 1000)
raport <- list()
argumenty <- commandArgs(trailingOnly = TRUE)

if(length(argumenty) == 0) {
  plik <- "przykladoweDane-Projekt.csv"
  cat("Nie podano pliku wejściowego\n")
  cat("Wczytano domyślny plik: ", plik, "\n\n")
} else {
  plik <- argumenty[1]
  cat("Wczytano plik:", plik, "\n\n")
}

dane <- read.csv2(plik, stringsAsFactors = FALSE, dec = ",")
raport$nazwaPliku <- plik
```

Wczytywanie bibliotek i pliku wejściowego - jeśli użytkownik nie poda własnego pliku, który chce poddać analizie, to skrypt przyjmuje domyślnie plik *przykladoweDane-Projekt.csv*

```
nazwaKolGrupa <- colnames(dane)[1]
dane[[nazwaKolGrupa]] <- as.factor(dane[[nazwaKolGrupa]])
poziomyGrup <- levels(dane[[nazwaKolGrupa]])

indeksyNumeryczne <- which(sapply(dane, is.numeric))
kolumnyNumeryczne <- names(dane)[indeksyNumeryczne]

tabelaZmian <- data.frame(Kolumna = character(), BrakiDanych = numeric(), WstawionaSrednia = numeric())
listaWartosciOdstajacych <- list()
```

Strukturyzacja danych i identyfikacja kolumn - Skrypt automatycznie pobiera nazwę pierwszej kolumny. Następnie za pomocą `as.factor()` zamienia zwykły tekst z tej kolumny w tzw. faktor (kategorię). Jest to kluczowe, ponieważ testy statystyczne (jak ANOVA) wymagają ścisłego matematycznego podziału na grupy, a nie zwykłych wyrazów. Zmienna `poziomyGrup <- levels(...)` zapisuje unikalne nazwy tych grup (CHOR1, CHOR2, KONTROLA). Skrypt używa funkcji `is.numeric`, aby przeszukać tabelę i zapisać do zmiennej `kolumnyNumeryczne` wyłącznie te kolumny, w których znajdują się liczby. Dzięki temu program nie zgłosi błędu, próbując liczyć średnią np. z nazwiska pacjenta.

```
for(i in indeksyNumeryczne) {
  nazwaKol <- colnames(dane)[i]

  # Imputacja
  liczbaNa <- sum(is.na(dane[, i]))
  if(liczbaNa > 0) {
    sredniaVal <- mean(dane[, i], na.rm = TRUE)
    tabelaZmian <- rbind(tabelaZmian, data.frame(
      Kolumna = nazwaKol,
      BrakiDanych = liczbaNa,
      WstawionaSrednia = round(sredniaVal, 2)
    ))
    dane[, i] <- as.numeric(impute(dane[, i], sredniaVal))
  }

  # Outliery
  outliers <- boxplot.stats(dane[[i]])$out
  if(length(outliers) > 0) {
    listaWartosciOdstajacych[[nazwaKol]] <- outliers
  }
}
raport$tabelaZmian <- tabelaZmian
raport$outliers <- listaWartosciOdstajacych
```

Imputacja - Skrypt pętlą przechodzi przez każdą kolumnę liczbową. Jeśli wykryje braki danych (NA), wylicza średnią z dostępnych wyników (`mean`). Następnie funkcja `rbind` (Row Bind - "doklej wiersz") dokleja do tabeli zmian nowy wiersz z informacją: jaka to kolumna, ile było braków i jaką średnią je zastąpiono. Zastąpienie wartości fizycznie odbywa się funkcją `impute()`.

Identyfikacja Outlierów - Przy użyciu metody `boxplot.stats()`\$out skrypt sprawdza rozstęp międzykwartylowy. Jeśli znajdzie wyniki skrajnie odstające, zapisuje je na liście.

```
#Charakterystyka Grup
charSzeroka <- dane %>%
  group_by(.data[[nazwaKolGrupa]]) %>%
  summarise(across(all_of(kolumnyNumeryczne), list(
    Sr = ~round(mean(., na.rm = TRUE), 2),
    Md = ~round(median(., na.rm = TRUE), 2),
    SD = ~round(sd(., na.rm = TRUE), 2)
  ), .names = "{.col}_{.fn}"))

charLong <- as.data.frame(t(charSzeroka[, -1]))
colnames(charLong) <- charSzeroka[[1]]

charLong <- cbind(Parametr = rownames(charLong), charLong)
raport$charakterystyka <- charLong
```

Charakterystyka Grup - Skrypt wykorzystuje bibliotekę dplyr. Polecenie `group_by` dzieli pacjentów na odpowiednie grupy. Następnie funkcja `summarise(across(all_of(kolumnyNumeryczne)...))` nakazuje wyliczyć średnią, medianę i odchylenie standardowe dla tych kolumn liczbowych, które zostały zidentyfikowane w poprzednim etapie (`all_of` pilnuje, aby użyć dokładnie tej listy). Wyniki są transponowane (obracane z poziomu w pion za pomocą `t()`) dla lepszej czytelności.

```
if (normalny && jednorodna) {
  testType <- "Parametryczny (ANOVA)"
  modelAov <- aov(formulaTest, data = dane)
  glownyP <- summary(modelAov)[[1]][["Pr(>F)"]][1]
  if (glownyP < 0.05) {
    ph <- TukeyHSD(modelAov)
    pary <- ph[[nazwaKolGrupa]][ph[[nazwaKolGrupa]][, "p adj"] < 0.05, , drop = FALSE]
    if (nrow(pary) > 0) opisPostHoc <- paste(rownames(pary), collapse = "; ")
  }
} else {
  testType <- "Nieparametryczny (Kruskal-Wallis)"
  testKW <- kruskal.test(formulaTest, data = dane)
  glownyP <- testKW$p.value
  if (glownyP < 0.05) {
    ph <- dunnTest(formulaTest, data = dane, method = "bonferroni")
    pary <- ph$res[ph$res$P.adj < 0.05, ]
    if (nrow(pary) > 0) opisPostHoc <- paste(pary$Comparison, collapse = "; ")
  }
}

listawynikowTestow[[param]] <- data.frame(
  Parametr = param, Normalnosc = ifelse(normalny, "OK", "Brak"),
  Wariancja = ifelse(jednorodna, "OK", "Brak"), Test = testType,
  Pvalue = round(glownyP, 5), Istotne_roznice = ifelse(glownyP < 0.05, "TAK", "NIE"),
  Miedzy_grupami = opisPostHoc
)

raport$tabelaPorownawcza <- do.call(rbind, listawynikowTestow)
```

```
#Analiza Porównawcza
listawynikowTestow <- list()
for (param in kolumnyNumeryczne) {
  formulaTest <- as.formula(paste(param, "~", nazwaKolGrupa))

  shapiroP <- tapply(dane[[param]], dane[[nazwaKolGrupa]], function(x) shapiro.test(x)$p.value)
  normalny <- all(shapiroP > 0.05)
  wariancjaP <- leveneTest(formulaTest, data = dane)$`Pr(>F)`[1]
  jednorodna <- wariancjaP > 0.05

  opisPostHoc <- "Brak istotnych różnic"
```

Analiza Porównawcza - Skrypt wykorzystuje funkcję `as.formula`, która zamienia ciąg tekstowy (np. "HGB ~ Grupa") na równanie matematyczne, które testy traktują jako polecenie: „zbadaj zależność parametru HGB względem przynależności do Grupy”. Skrypt wylicza p-value dla testu Shapiro-Wilka i Levene’a. Jeśli oba warunki są spełnione, skrypt przeprowadza test ANOVA (`aov`). Zmienna `glownyP` przechowuje jego wynik. Jeśli test wskaże różnice ($p\text{-value} < 0.05$), skrypt uruchamia również test post-hoc TukeyHSD. W przypadku niespełnienia warunków skrypt uruchamia `kruskal.test` oraz post-hoc `dunnTest`.


```
#Analiza korelacji
listaKorelacji <- list()
for(grp in poziomyGrup) {
  podgrupa <- dane[dane[[nazwaKolGrupa]] == grp, ]
  pary <- combn(kolumnyNumeryczne, 2)
  for(i in 1:ncol(pary)) {
    p1 <- pary[1,i]; p2 <- pary[2,i]
    testKor <- cor.test(podgrupa[[p1]], podgrupa[[p2]], method = "spearman", exact = FALSE)
    if(testKor$p.value < 0.05) {
      listaKorelacji[[length(listaKorelacji) + 1]] <- data.frame(
        Grupa = grp, Parametr_1 = p1, Parametr_2 = p2,
        Wspolczynnik_R = round(testKor$estimate, 3), Pvalue = round(testKor$p.value, 5)
      )
    }
  }
}
raport$tabelaKorelacji <- if(length(listaKorelacji) > 0) do.call(rbind, listaKorelacji) else "Brak istotnych statystycznie korelacji."
```

Analiza Korelacji - Skrypt dzieli dane na podgrupy (np. tylko KONTROLA). Funkcja `combn(kolumnyNumeryczne, 2)` tworzy matematyczne kombinacje wszystkich możliwych par parametrów (np. HGB z HCT, HGB z wiekiem), aby niczego nie pominąć. Skrypt przeprowadza test Spearmana dla każdej pary i jeśli wynik jest istotny ($p\text{-value} < 0.05$), zapisuje go na listę.

```
#RAPORT
sink("Raport.txt")
cat("RAPORT STATYSTYCZNEJ ANALIZY DANYCH\n")
cat("Plik wejściowy:", raport$nazwaPliku, "\n")

cat("\n1. PRZYGOTOWANIE DANYCH\n\n")
if(nrow(raport$tabelaZmian) > 0) {
  print(raport$tabelaZmian)
}else {
  cat("Brak braków danych.\n")
}

cat("\nWARTOŚCI ODSTAJĄCE:\n\n")
for(n in names(raport$outliers)) {
  cat(paste0(n, ": ", paste(raport$outliers[[n]], collapse=" "), "\n"))
}

cat("\n2. CHARAKTERYSTYKA GRUP\n\n")
print.data.frame(as.data.frame(raport$charakterystyka), row.names = FALSE)

cat("\n3. ANALIZA PORÓWNAWCZA\n\n")
print.data.frame(raport$tabelaPorownawcza, row.names = FALSE)

cat("\n4. ANALIZA KORELACJI W GRUPACH\n\n")
if(is.data.frame(raport$tabelaKorelacji)) {
  print.data.frame(raport$tabelaKorelacji, row.names = FALSE)
} else {
  cat(raport$tabelaKorelacji, "\n")
}
sink()
```

Generowanie Raportu - Skrypt zapisuje w pliku tekstowym raport składający się z: nazwy analizowanego pliku, tabeli modyfikacji i listy wartości odstających, statystyk opisowych grup, wyników testów różnic wraz z interpretacją post-hoc oraz macierzy korelacji.

```

#WYKRESY
pdf("wykresy.pdf", width = 10, height = 7)
liczbaGrup <- length(poziomyGrup)
kolory <- colorRampPalette(c("#ffc8dd", "#ffaacc", "#fb6f92"))(liczbaGrup)
koloryMacierzy <- colorRampPalette(c("#a2d2ff", "white", "#ffaacc"))(200)

# Boxplot
for(param in kolumnyNumeryczne) {
  Pval <- raport$tabelaPorownawcza$Pvalue[raport$tabelaPorownawcza$Parametr == param]
  boxplot(as.formula(paste(param, "~", nazwaKolGrupa)),
    data = dane,
    main = paste("Rozkład:", param, "\np-value =", Pval),
    col = kolory,
    border = "#5D5D5D",
    xlab = "Grupa", ylab = "Wartość")
}

# Heatmapy
for(grp in poziomyGrup) {
  danePodgrupa <- dane[dane[[nazwaKolGrupa]] == grp, kolumnyNumeryczne]
  macierzKor <- cor(danePodgrupa, method = "spearman")

  corrpplot(macierzKor,
    method = "color",
    type = "upper",
    col = koloryMacierzy,
    addCoef.col = "#4D4D4D",
    tl.col = "black", tl.srt = 45,
    title = paste("\nMacierz korelacji - Grupa:", grp),
    mar = c(0,0,3,0))
}

```

```

# Scatterplots
if(is.data.frame(raport$tabelaKorelacji)) {
  for(i in 1:nrow(raport$tabelaKorelacji)) {
    g <- raport$tabelaKorelacji$Grupa[i]
    p1 <- raport$tabelaKorelacji$Parametr_1[i]
    p2 <- raport$tabelaKorelacji$Parametr_2[i]

    kolorId <- which(poziomyGrup == g)
    dSub <- dane[dane[[nazwaKolGrupa]] == g, ]

    plot(dSub[[p1]], dSub[[p2]],
      main = paste("Korelacja:", g, "|", p1, "vs", p2),
      xlab = p1, ylab = p2,
      pch = 21, bg = kolory[kolorId],
      col = "#5D5D5D", cex = 1.6)

    abline(lm(dSub[[p2]] ~ dSub[[p1]]), col = "#a2d2ff", lwd = 2.5)
  }
}

dev.off()

cat("\nPROJEKT ZAKOŃCZONY!\nSprawdź pliki Raport.txt oraz Wykresy.pdf\n")

```

Generowanie Wykresów - Skrypt automatycznie tworzy wielostronicowy dokument PDF zawierający wykresy pudełkowe z naniesionymi wartościami p-value, kolorowe macierze korelacji dla poszczególnych grup oraz wykresy rozrzutu z liniami trendu, generowane wyłącznie dla par parametrów o istotnej zależności statystycznej.

3. Opis wyników analizy:

-> Wykresy:


Wygenerowane przez skrypt wykresy są zapisywane w pliku **Wykresy.pdf**.

-> **Wykresy pudełkowe (Boxplots)** - Prezentują rozkład danych dla każdego badanego parametru. Służą do szybkiego, wizualnego porównania median i rozrzutu wyników w grupach, a także pokazują wartości skrajnie odstające jako pojedyncze kropki.


-> **Macierze korelacji (Heatmaps)** - Prezentują korelacje pomiędzy wszystkimi wartościami w poszczególnych grupach za pomocą kolorów. W zależności od odcienia koloru można ocenić siłę i kierunek powiązań wartości dla całej grupy badawczej.

-> **Wykresy rozrzutu (Scatterplots)** - Prezentują korelacje pomiędzy konkretnymi wartościami, dla których skrypt znalazł istotną zależność. Pokazują dokładne wyniki pojedynczych pacjentów jako kropki na tle poprowadzonej linii trendu, pokazując, jak jeden parametr zachowuje się względem drugiego.


-> **Wyniki analizy:**




Na wykresie przedstawiono rozkład wieku w trzech badanych grupach. Z wykresu wynika, że badane grupy nie różnią się od siebie istotnie pod względem wieku, ze względu na to, że wartość p-value wynosi 0.20563.




Wykres prezentuje poziom hemoglobiny(HGB) w grupach CHOR1, CHOR2 i KONTROLA. Bardzo niskie p-value wskazuje na istnienie silnych różnic statystycznych, szczególnie widocznych między grupami chorobowymi a grupą kontrolną.



Wykres przedstawia macierz wszystkich korelacji w grupie kontrolnej. Kolory i liczby pozwalają ocenić siłę oraz kierunek powiązań. Przykładowo widać bardzo silną dodatnią relację między HGB a HCT (0.92). Dodatnia korelacja (różowa) oznacza, że parametry rosną jednocześnie, natomiast ujemna (niebieska), widoczna np. między wiekiem a LEU (-0.52), wskazuje, że wzrost jednej wartości wiąże się ze spadkiem drugiej.



Na wykresie przedstawiono korelację w grupie kontrolnej pomiędzy wiekiem a poziomem leukocytów (LEU). Spadająca fioletowa linia trendu wskazuje na ujemną zależność, co oznacza, że w tej grupie wraz z wiekiem poziom leukocytów ma tendencję spadkową.



Wykres pokazuje korelację między hemoglobiną (HGB) a hematokrytem (HCT) w grupie CHOR2. Rosnąca linia regresji oraz skupienie punktów blisko niej dowodzą istnienia bardzo silnej, dodatniej korelacji między tymi dwoma parametrami krwi.

->Raport:

Wygenerowany przez skrypt raport jest zapisywany w pliku **Raport.txt**.

```
RAPORT STATYSTYCZNEJ ANALIZY DANYCH
Plik wejściowy: przykladoweDane-Projekt.csv

1. PRZYGOTOWANIE DANYCH

    Kolumna BrakiDanych WstawionaSrednia
1      HGB          2      12.17
2      MON          1       0.86

WARTOŚCI ODSTAJĄCE:

wiek: 48
hsCRP: 20.1548, 16.4069, 42.6499, 19.2124
ERY: 33
PLT: 456, 434
HGB: 22.2318
HCT: 0.0423
MCHC: 38.8674, 38.203, 32.0573, 32.2234
MON: 1.5, 1.52, 0.14, 1.61, 7
```

Sekcja Przygotowania Danych: Podsumowuje przygotowanie zbioru danych, w tym liczbę uzupełnionych braków oraz listę wartości odstających(outliers).

Przykładowo, dla hemoglobiny (HGB) uzupełniono 2 braki średnią 12.17, a wartość 22.2318 została uznana za odstającą, co pozwala na dalszą, rzetelną analizę statystyczną.

2. CHARAKTERYSTYKA GRUP

Parametr	CHOR1	CHOR2	KONTROLA
wiek_Sr	29.56	30.04	32.32
wiek_Md	29.00	30.00	32.00
wiek_SD	5.88	5.90	5.61
hsCRP_Sr	6.10	5.54	5.30
hsCRP_Md	3.97	3.45	4.22
hsCRP_SD	8.82	4.65	4.00
ERY_Sr	5.36	4.20	4.01
ERY_Md	4.20	4.27	3.98
ERY_SD	5.77	0.47	0.46
PLT_Sr	225.28	209.12	225.88
PLT_Md	217.00	195.00	214.00
PLT_SD	54.22	75.22	63.81
HGB_Sr	12.40	12.81	11.30
HGB_Md	12.40	12.57	11.44
HGB_SD	1.19	2.37	1.07
HCT_Sr	0.36	0.35	0.34
HCT_Md	0.36	0.36	0.34
HCT_SD	0.03	0.07	0.03
MCHC_Sr	35.13	35.55	34.40
MCHC_Md	35.05	35.55	34.55
MCHC_SD	0.88	1.29	1.12
MON_Sr	0.86	0.95	0.76
MON_Md	0.76	0.66	0.76
MON_SD	0.29	1.30	0.19
LEU_Sr	12.02	12.04	11.36
LEU_Md	11.66	12.00	10.68
LEU_SD	2.58	2.32	3.08

Sekcja Charakterystyki Grup: Tabela zawiera statystyki opisowe (średnia (_Sr), mediana (_Md), odchylenie standardowe (_SD)) dla wszystkich badanych parametrów medycznych w podziale na grupy pacjentów.

Pozwala to na szybkie porównanie poziomów parametrów np. średni poziom HGB w grupie kontrolnej (11.29) jest niższy niż w grupach chorobowych (12.40 i 12.80).

3. ANALIZA PORÓWNAWCZA

Parametr	Normalność	Wariancja	Test	Pvalue	Istotne_rownice	Miedzy_grupami
wiek	OK	OK	Parametryczny (ANOVA)	0.20563	NIE	Brak istotnych różnic
hsCRP	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.88072	NIE	Brak istotnych różnic
ERY	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.15435	NIE	Brak istotnych różnic
PLT	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.32403	NIE	Brak istotnych różnic
HGB	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.00113	TAK	CHOR1 - KONTROLA; CHOR2 - KONTROLA
HCT	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.01896	TAK	CHOR1 - KONTROLA
MCHC	OK	OK	Parametryczny (ANOVA)	0.00186	TAK	KONTROLA-CHOR2
MON	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.25421	NIE	Brak istotnych różnic
LEU	OK	OK	Parametryczny (ANOVA)	0.59650	NIE	Brak istotnych różnic

Sekcja Analizy Porównawczej: Analiza porównawcza została przeprowadzona z wykorzystaniem automatycznego doboru testów statystycznych, uzależnionego od weryfikacji założeń o normalności rozkładu (test Shapiro-Wilka) oraz jednorodności wariancji (test Levene'a).

W przypadku parametrów spełniających oba założenia zastosowano jednoczynnikową analizę wariancji (ANOVA - porównanie średnich wartości między grupami), natomiast dla pozostałych

parametrów wykorzystano nieparametryczny test Kruskala-Wallisa(rangowanie danych - gwarantuje odporność na wpływ outlierów).

Uzyskane wartości istotności dla HGB ($p=0.00113$) oraz HCT ($p=0.01896$) pozwalają stwierdzić występowanie istotnych statystycznie odchyleń między badanymi grupami, co zostało potwierdzone szczegółowymi testami post-hoc Tukeya(ANOVA) lub Dunna(Kruskala-Wallisa) wskazującymi na konkretne pary grup np. w parametrze HGB różnice występują pomiędzy obiema grupami chorobowymi a grupą kontrolną, a nie między samymi stadiami choroby.

4. ANALIZA KORELACJI W GRUPACH

Grupa	Parametr_1	Parametr_2	Wspolczynnik_R	Pvalue
CHOR1	ERY	HGB	0.640	0.00058
CHOR1	ERY	HCT	0.615	0.00107
CHOR1	HGB	HCT	0.966	0.00000
CHOR1	HGB	MCHC	0.553	0.00414
CHOR1	HCT	MCHC	0.418	0.03783
CHOR2	ERY	HGB	0.883	0.00000
CHOR2	ERY	HCT	0.751	0.00001
CHOR2	PLT	MCHC	-0.519	0.00780
CHOR2	HGB	HCT	0.737	0.00003
KONTROLA	wiek	ERY	0.564	0.00333
KONTROLA	wiek	MCHC	-0.408	0.04266
KONTROLA	wiek	LEU	-0.516	0.00834
KONTROLA	hsCRP	LEU	0.425	0.03401
KONTROLA	ERY	PLT	0.454	0.02253
KONTROLA	ERY	HGB	0.466	0.01892
KONTROLA	ERY	HCT	0.679	0.00019
KONTROLA	ERY	MCHC	-0.511	0.00907
KONTROLA	HGB	HCT	0.917	0.00000

Sekcja korelacji: Przedstawia siłę i kierunek zależności między parametrami krwi przy użyciu współczynnika Spearmana(porównaniu pozycji dwóch parametrów, sprawdzając, czy wyższe miejsca w jednym badaniu odpowiadają wyższemu lub niższemu miejscu w drugim).

Współczynnik R (rho) określa siłę tej zależności: wartość dodatnia oznacza, że parametry rosną jednocześnie, a ujemna - że wzrost jednego wiąże się ze spadkiem drugiego.

Na wykresach i w tabeli widać silne zależności - przykładowo w grupie CHOR1 hemoglobina (HGB) i hematokryt (HCT) mają prawie idealną korelację ($R=0.966$), więc zawsze rosną lub spadają razem.

4. Analiza dla innych plików wejściowych:

-> Ograniczenia dotyczące wczytywania plików .csv:

- > Pierwsza kolumna musi zawierać nazwę grupy, do której należy pacjent
- > Plik musi być formatu Semicolon Separated (średnik - separator kolumn, przecinek - separator dziesiętny)
- > W przypadku braku danych powinny znaleźć się puste pola, a nie np tekst „Brak danych”, taka kolumna zostanie oznaczona jako typu character i całkowicie pominięta w analizie.

-> Każda grupa powinna mieć co najmniej 3-5 pacjentów, ponieważ Test Shapiro-Wilka wymaga co najmniej 3 obserwacji, w przeciwnym wypadku może skrypt może napotkać błędy.

-> Analiza pliku DaneHormonalne.csv:

Analizie statystycznej poddano plik DaneHormonalne.csv, w którym zbadano poziomy pięciu parametrów hormonalnych (estrogenu, progesteronu, LH, FSH oraz AMH) u pacjentek podzielonych na cztery badane grupy: kontrolną, z PCOS, z endometriozą oraz z mięśniakami.

RAPORT STATYSTYCZNEJ ANALIZY DANYCH				
Plik wejściowy: DaneHormonalne.csv				
1. PRZYGOTOWANIE DANYCH				
	Kolumna	BrakiDanych	Wstawiona	Srednia
1	Progesteron	1		1.46
2	AMH	1		3.65
WARTOŚCI ODSTAJĄCE:				
Estrogen: 150				
LH: 15.8, 14.2, 18.5, 16.1, 17				
AMH: 8.5, 9.1, 7.8, 10.2, 8.9				
2. CHARAKTERYSTYKA GRUP				
Parametr	ENDOMETRIOZA	KONTROLA	MIESNIAKI	PCOS
Estrogen_Sr	94.36	46.72	84.67	36.98
Estrogen_Md	92.10	47.00	71.95	37.50
Estrogen_SD	9.83	2.76	32.08	2.48
Progesteron_Sr	1.10	1.20	2.65	0.65
Progesteron_Md	1.10	1.20	2.65	0.50
Progesteron_SD	0.27	0.22	0.30	0.47
LH_Sr	6.30	5.34	4.97	16.32
LH_Md	6.10	5.10	4.95	16.10
LH_SD	0.57	0.53	0.33	1.58
FSH_Sr	5.44	4.96	4.15	3.14
FSH_Md	5.50	5.00	4.15	3.10
FSH_SD	0.44	0.21	0.24	0.23
AMH_Sr	1.89	2.10	2.05	8.90
AMH_Md	1.50	2.10	2.05	8.90
AMH_SD	1.00	0.27	0.19	0.88


Przygotowanie Danych - Skrypt pomyślnie uzupełnił pojedyncze braki średnimi wartościami dla progesteronu i AMH oraz zidentyfikował skrajne wartości odstające w trzech parametrach.

Charakterystyka Grup - Tabela wykazuje, że średni poziom hormonu LH oraz AMH w grupie PCOS jest drastycznie wyższy niż w pozostałych schorzeniach, natomiast pacjentki z endometriozą i mięśniakami wyróżniają się najwyższym stężeniem estrogenu.

3. ANALIZA PORÓWNAWCZA					
Parametr	Normalnosc	Wariancja	Test	Pvalue	Istotne_roznice
Miedzy_grupami					
Estrogen	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.00054	TAK
ENDOMETRIOZA - PCOS; MIESNIAKI - PCOS					
Progesteron	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.00210	TAK
MIESNIAKI - PCOS					
LH	OK	OK	Parametryczny (ANOVA)	0.00000	TAK PCOS-ENDOMETRIOZA;
PCOS-KONTROLA; PCOS-MIESNIAKI					
FSH	OK	OK	Parametryczny (ANOVA)	0.00000	TAK MIESNIAKI-ENDOMETRIOZA; PCOS-ENDOMETRIOZA; MIESNIAKI-KONTROLA;
PCOS-KONTROLA; PCOS-MIESNIAKI					
AMH	Brak	OK	Nieparametryczny (Kruskal-Wallis)	0.00462	TAK
ENDOMETRIOZA - PCOS					
4. ANALIZA KORELACJI W GRUPACH					
Grupa	Parametr_1	Parametr_2	Wspolczynnik_R	Pvalue	
ENDOMETRIOZA	Estrogen	Progesteron	0.900	0.03739	
	Progesteron	LH	-1.000	0.00000	
KONTROLA	FSH	AMH	-0.900	0.03739	
	Estrogen	Progesteron	0.943	0.00480	
MIESNIAKI	Estrogen	AMH	1.000	0.00000	
	Progesteron	FSH	-1.000	0.00000	


Analiza Porównawcza - Skrypt potwierdził istnienie silnych odchyleń we wszystkich badanych hormonach, precyzyjnie wskazując, że na przykład w przypadku progesteronu główna różnica występuje między grupą z mięśniakami a pacjentkami z PCOS.

Analiza Korelacji - Wykazała bardzo silne powiązania układu hormonalnego, w tym idealnie dodatnią zależność między estrogenem a AMH przy PCOS, co oznacza, że te hormony zawsze rosną jednocześnie.




Wykres pudełkowy wizualnie potwierdza istotne różnice między badanymi grupami - wyraźnie widać, że pacjentki z mięśniakami charakteryzują się najwyższym stężeniem tego hormonu, podczas gdy w grupie PCOS jego poziom jest zdecydowanie najniższy.

Porównanie grupy kontrolnej(zdrowej) i chorej na endometriozę:



W zdrowej grupie kontrolnej progesteron i LH wykazują idealną korelację ujemną ($R = -1,0$), co odzwierciedla prawidłowe, fizjologiczne sprzężenie zwrotne hamujące wydzielanie hormonu LH. Z kolei całkowity brak tej zależności u pacjentek z endometriozą stanowi dowód na patologiczne zerwanie tego naturalnego mechanizmu i rozregulowanie osi hormonalnej w przebiegu choroby.



Wykres punktowy z wykreśloną linią trendu wizualnie udowadnia idealną korelację dodatnią obu parametrów u pacjentek z zespołem PCOS. Perfekcyjne ułożenie wyników na linii wznoszącej obrazuje wprost, że w tej jednostce chorobowej wzrostowi stężenia estrogenu bezwzględnie i proporcjonalnie towarzyszy wzrost poziomu AMH.